

Softverski algoritmi u sistemima automatskog upravljanja

Linearni modeli za regresiju i klasifikaciju

Emina Demirović

Katedra za automatsko upravljanje
Departman za računarstvo i automatiku
Fakultet tehničkih nauka

Sadržaj termina

- ▶ linearni modeli - osnovna ideja
- ▶ linearna regresija
- ▶ greška predikcije i loss funkcija
- ▶ metoda najmanjih kvadrata
- ▶ višestruka linearna regresija
- ▶ interpretacija koeficijenata modela
- ▶ regularizacija
- ▶ Ridge i Lasso regresija
- ▶ skaliranje atributa
- ▶ logistička regresija
- ▶ sigmoid funkcija
- ▶ prag i granica odlučivanja

Linearni modeli - osnovna ideja

Svaki model ima istu osnovnu logiku:

1. model napravi predikciju,
2. izmeri se koliko je predikcija pogrešna,
3. greške se objedine kroz loss funkciju,
4. parametri se podešavaju tako da loss bude što manji.

podaci $\rightarrow$ model $\rightarrow$ greška $\rightarrow$ učenje parametara

Učenje modela se svodi na traženje parametara koji daju najmanju grešku na podacima za obučavanje.

Linearni modeli

Linearan model daje izlaz (predikciju) kao linearnu funkciju (kombinaciju) ulaznih atributa.

Slučaj sa jednim atributom:

$$\hat{y} = ax + b$$

Slučaj sa više atributa:

$$\hat{y} = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

- ▶ $x_1, x_2, \dots, x_n$ su atributi,
- ▶ $w_1, w_2, \dots, w_n$ su koeficijenti,
- ▶ b je slobodan član,
- ▶ $\hat{y}$ je predikcija modela.

Parametri modela

Parametri modela su vrednosti koje model uči iz podataka.

Kod linearne regresije, model uči:

$$a \text{ i } b$$

odnosno, u slučaju više atributa:

$$w_1, w_2, \dots, w_n \text{ i } b$$

Atributi su ulazni podaci.

Parametri su vrednosti koje model uči iz podataka, odnosno, ono što sam podešava tokom obučavanja.

Regresioni model treba da nauči funkciju koja povezuje ulaz x_i sa izlazom y_i .

Linearna regresija

Linearna regresija modeluje odnos između ulaznih promenljivih i ciljnog izlaza tako da izlazna vrednost linearno zavisi od ulaza.

Za najjednostavniji slučaj sa jednom promenljivom, model ima oblik jednačine prave:

$$\hat{y}_i = ax_i + b$$

Ovo je poznati oblik: $y = ax + b$

ali u mašinskom učenju u opštem slučaju važi: $y_i \neq \hat{y}_i$

- ▶ y_i - stvarna vrednost iz podataka
- ▶ $\hat{y}_i$ - vrednost koju predviđa model

Linearna regresija ne traži pravu koja prolazi kroz sve tačke, već pravu koja najbolje opisuje vezu između ulaza i izlaza i pri tome pravi najmanju ukupnu grešku.

Linearna regresija

Linearna regresija je linearna po parametrima, ne nužno po originalnim atributima.

`fit()`: pronadi parametre koji najbolje odgovaraju podacima za obučavanje.

Prednosti

- ▶ model jednostavan za tumačenje i implementaciju
- ▶ brzo obučavanje i predikcija (čak i za veće skupove podataka)
- ▶ dobra polazna referentna tačka (baseline model)

Ograničenja

- ▶ pretpostavka linearne veze između atributa i izlaza
- ▶ osetljivost na anomalije u podacima
- ▶ problematično kada su ulazni atributi snažno međusobno povezani

Rezidual

Za svaki primer iz skupa podataka model napravi predikciju:

$$\hat{y}_i = w^T x_i + b$$

Razlika između stvarne vrednosti i predikcije naziva se rezidual:

$$r_i = y_i - \hat{y}_i \implies r_i = y_i - (w^T x_i + b)$$

Cilj nije da jedan rezidual (greška na jednom primeru) bude mali, već da model pravi male greške na celom skupu podataka.

Loss funkcija

Za n primera postoji n reziduala

⇒ potrebna jedna funkcija koja meri ukupnu grešku modela

Loss funkcija

Loss funkcija meri odstupanje između stvarne vrednosti i predikcije modela, pri čemu model ima za cilj da je minimizuje tokom obuke.

Kod linearne regresije često se koristi suma kvadratnih reziduala:

$$RSS(w, b) = \sum_{i=1}^n r_i^2 = \sum_{i=1}^n \left(y_i - (w^T x_i + b) \right)^2$$

Zašto je kvadratna greška pogodna za upotrebu?

Kvadratne greške

Metoda najmanjih kvadrata bira parametre tako da suma kvadratnih grešaka bude minimalna, odnosno, optimizacioni problem glasi:

$$\min_{w,b} \sum_{i=1}^n \left(y_i - (w^T x_i + b) \right)^2$$

Često se koristi i srednja kvadratna greška:

$$MSE(w, b) = \frac{1}{n} \sum_{i=1}^n \left(y_i - (w^T x_i + b) \right)^2$$

Najbolji parametri su oni koji minimizuju izabranu funkciju greške.

Višestruka linearna regresija

Za n atributa model je:

$$\hat{y}_i = w_1x_{i1} + w_2x_{i2} + \dots + w_nx_{in} + b$$

Kod višestruke linearne regresije koristi više ulaznih atributa, pri čemu svaki od njih dobija svoj koeficijent.

Primer - predikcija cena nekretnina:

$$\widehat{\text{cena}} = w_1 \cdot \text{površina} + w_2 \cdot \text{broj soba} + w_3 \cdot \text{lokacija} + b$$

Interpretacija koeficijenata

Koeficijent pokazuje kako se predikcija menja kada se atribut promeni.

Matematički:

$$\Delta \hat{y} = w_j \Delta x_j$$

pod pretpostavkom da se ostali atributi ne menjaju.

Zato važi:

- ▶ $w_j > 0$ - atribut povećava predikciju
- ▶ $w_j < 0$ - atribut smanjuje predikciju
- ▶ $w_j \approx 0$ - atribut ima neznatan linearni uticaj

Koeficijenti nisu uvek direktno uporedivi!

Geometrijska intuicija

Jednostavna geometrijska interpretacija linearnog modela:

- ▶ jedan atribut - prava
- ▶ dva atributa - ravan
- ▶ više atributa - hiperravan

Linearan model traži jednostavnu površinu koja najpribližnije opisuje odnos između ulaza i izlaza.

Regularizacija

Regularizacija

Regularizacija je tehnika u mašinskom učenju kojom se u funkciju greške dodaje kazneni član, sa ciljem da se model obeshrabri u učenju previše kompleksnih šablona i da se spreči ekstremno visoka vrednost njegovih parametara.

- ▶ smanjuje rizik od preprilagođavanja
- ▶ pomaže kod multikolinearnosti
- ▶ stabilizuje model (mala varijansa)

$$\text{loss} = \text{greška predviđanja} + \text{kazna za kompleksnost}$$

Ridge regresija

Ridge regresija koristi L2 regularizaciju.

Ciljna funkcija ima oblik:

$$\min_w \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p w_j^2$$

- ▶ prediktor (prvi deo) meri grešku predviđanja
- ▶ regulator (drugi deo) kažnjava velike koeficijente
- ▶ parametar λ kontroliše jačinu kazne

Efekat Ridge regularizacije

Ridge regresija smanjuje koeficijente, ali ih najčešće ne svodi tačno na nulu

- ▶ svi atributi uglavnom ostaju u modelu
- ▶ veliki koeficijenti se ublažavaju
- ▶ model postaje stabilniji
- ▶ posebno pomaže kada su atributi međusobno povezani

Lasso regresija

Lasso regresija koristi L1 regularizaciju.

Ciljna funkcija ima oblik:

$$\min_{w,b} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |w_j|$$

- ▶ prediktor (prvi deo) meri grešku predviđanja
- ▶ regularizaciona kazna (drugi član) zasnovana na apsolutnim vrednostima koeficijenata

Lasso može svesti koeficijente tačno na nulu
i atribut u tom slučaju neće uticati na predikciju.

Lasso se može posmatrati kao jednostavan oblik izbora atributa.

Uloga parametra λ

Parametar λ određuje koliko je regularizacija jaka.

- ▶ malo $\lambda \implies$ model se više oslanja na smanjenje greške
- ▶ veliko $\lambda \implies$ model jače kažnjava velike koeficijente

Šta ako je λ previše malo/veliko?

Regularizacija je balans između tačnosti na trening podacima i jednostavnosti modela.

Ridge stabilizuje model, a Lasso može dodatno pojednostaviti model izborom atributa.

Skaliranje atributa

Skaliranjem se atributi dovode na uporedive numeričke opsege.

Standardizacija:

$$x' = \frac{x - \mu}{\sigma}$$

gde su:

- ▶ μ srednja vrednost atributa,
- ▶ σ standardna devijacija atributa.

Zašto je neophodno kod regularizovanih linearnih modela?

Ako atributi nisu na sličnoj skali, koeficijenti nisu direktno uporedivi. Samim tim, ista regularizaciona kazna neće uticati jednako na sve.

Skaliranje i interpretacija koeficijenata

Posle skaliranja, koeficijenti se tumače drugačije.

Pre skaliranja:

- koeficijent se odnosi na promenu originalne jedinice mere.

Posle standardizacije:

- koeficijent se odnosi na promenu atributa za jednu standardnu devijaciju.

Zašto linearna regresija nije dovoljna za klasifikaciju?

Zašto linearna regresija nije dovoljna za klasifikaciju?

Kod binarne klasifikacije izlaz ima dve moguće vrednosti.

Direktnim korišćenjem linearne regresije dobijeni izlaz može biti bilo koji realan broj:

$$\hat{y} \in (-\infty, +\infty)$$

To nije pogodno za tumačenje kao verovatnoća, jer verovatnoća mora biti u opsegu:

$$P(y = 1 \mid x) \in [0, 1]$$

Ideja logističke regresije

Zadržati linearni izraz $w^T x + b$, ali ga transformisati funkcijom koja izlaz svodi na željeni opseg.

Logistička regresija

Logistička regresija se najčešće koristi za **binarnu klasifikaciju**.

Logistička regresija prvo računa linearnu kombinaciju ulaza:

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b = w^T x + b$$

Način realizacije

Linearna regresija daje kontinuirani izlaz, a logistička regresija transformiše taj izlaz u verovatnoću pripadnosti određenoj klasi koristeći logističku (sigmoidnu) funkciju.

Šta je sigmoidna funkcija?

Sigmoid funkcija

Vrednost z se preslikava u opseg $[0, 1]$ pomoću sigmoid funkcije:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Predikcija modela je:

$$P(y = 1 \mid x) = \sigma(w^T x + b)$$

- ▶ $z \gg 0 \implies \sigma(z) \approx 1,$
- ▶ $z \ll 0 \implies \sigma(z) \approx 0,$
- ▶ $z = 0 \implies \sigma(z) = 0.5.$

Linearni model daje score, a sigmoid ga pretvara u verovatnoću:
veći score vodi ka većoj procenjenoj verovatnoći pripadnosti određenoj klasi.

Prag odluke

Neka logistička regresija računa:

$$z = w^T x + b, \quad p = P(y = 1 \mid x) = \sigma(z)$$

Na osnovu verovatnoće koju daje logistička regresija potrebno je ustanoviti klase i zato se uvodi **prag odlučivanja**.

Model ne predviđa klasu direktno: prvo procenjuje verovatnoću pripadnosti, zatim bira prag odlučivanja i tek onda daje predikciju klase.

U najjednostavnijem slučaju:

$$\hat{y} = \begin{cases} 1, & P(y = 1 \mid x) \geq 0.5 \\ 0, & P(y = 1 \mid x) < 0.5 \end{cases}$$

Granica odlučivanja

Budući da je sigmoid funkcija monotonno rastuća i $\sigma(0) = 0.5$, granica između klasa nastaje kada je:

$$P(y = 1 \mid x) = 0.5 \iff z = 0 \iff w^T x + b = 0$$

Zaključak

Model vraća verovatnoću pripadnosti, ali odluka se donosi poređenjem sa pragom.

Za vrednosti na pragu odlučivanja, granica između klasa logističke regresije je linearna.

Logistički loss

$y = 1$, želimo da $p \rightarrow 1$

$y = 0$, želimo da $p \rightarrow 0$

Zato se koristi logistički loss - **binary cross-entropy**:

$$\ell(y, p) = -(y \log(p) + (1 - y) \log(1 - p))$$

Ideja

Model dobije malu grešku kada dodeli veliku verovatnoću tačnoj klasi, a veliku grešku kada dodeli veliku verovatnoću pogrešnoj klasi.

Nije isto biti malo nesiguran i biti potpuno siguran u pogrešan odgovor.

Višeklasna klasifikacija

Za klasifikaciju u više od dve klase koristi se **multinomijalna logistička regresija**.

Za svaku klasu k računa se score:

$$z_k = w_k^T x + b_k$$

Softmax funkcija pretvara lin. kombinacije u verovatnoće pripadnosti klasama:

$$P(y = k \mid x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, 2, \dots, K$$

Ideja

Ovaj model omogućava klasifikaciju uzoraka u više kategorija, pri čemu za svaku klasu izračunava verovatnoću, a uzorak dodeljuje onoj sa najvećom verovatnoćom.