

Softverski algoritmi u sistemima automatskog upravljanja

Evaluacija i generalizacija modela

Emina Demirović

Katedra za automatsko upravljanje
Departman za računarstvo i automatiku
Fakultet tehničkih nauka

Sadržaj termina

- ▶ evaluacija modela - koncept
- ▶ generalizacija
- ▶ mera generalizacije
- ▶ evaluacija klasifikacionih modela
- ▶ matrica konfuzije
- ▶ metrike evaluacije klasif. modela
- ▶ evaluacija regresionih modela
- ▶ metrike evaluacije regres. modela
- ▶ izbor evaluacione metrike
- ▶ evaluacione metrike u Python-u
- ▶ problem podele podataka

Evaluacija modela

Kako procenjujemo da li model zaista dobro radi?

Kako procenjujemo da li model zaista dobro radi?

Da li model dobro radi na novim, neviđenim podacima?

Šta je generalizacija?

Generalizacija je sposobnost modela da dobro radi na novoviđenim podacima.

Dobar model nije onaj koji je najbolji na trening skupu, već onaj koji stabilno radi na validacionim i testnim podacima.

Visoka tačnost na trening skupu može da znači dve stvari:

- ▶ model je zaista naučio koristan obrazac,
- ▶ model je samo zapamtio trening podatke.

Rezultat se uvek proverava na odvojenim podacima!

Kako merimo generalizaciju?

Generalizacija se procenjuje pomoću rezultata na validacionom ili test skupu.

Metrika evaluacije

Metrika evaluacije je numerička mera koja opisuje kvalitet predikcija modela, odnosno, koliko su bliske očekivanim rezultatima.

Kada model ne generalizuje dobro?

Underfitting i overfitting

Underfitting

Model je previše jednostavan - slabo se prilagođava obučavajućem skupu podataka i ne uspeva da zaključi kako formirati izlaz.

- ▶ loš rezultat na train skupu
- ▶ loš rezultat na validation skupu

Rešenje

- ▶ promeniti algoritam
- ▶ proširiti skup podataka

Overfitting

Model se previše dobro prilagođava obučavajućem skupu podataka.

- ▶ dobar rezultat na train skupu
- ▶ loš rezultat na validation/test skupu
- ▶ **dobro pamti, ali loše prilagođava**

Rešenje

- ▶ proširiti skup podataka
- ▶ regularizacija
- ▶ ansambl metode

Bias-variance trade-off

Bias opisuje koliko je model pojednostavio problem.

Variance opisuje koliko je model osetljiv na konkretan trening skup.

- ▶ visok bias $\rightarrow$ underfitting
- ▶ visoka varijansa $\rightarrow$ overfitting

Cilj - ravnoteža

Model dovoljno složen da uči obrazac, ali ne toliko složen da pamti šum.

Evaluacija klasifikacije

Klasifikacija

Klasifikacija je proces razvrstavanja podataka u unapred definisane kategorije, sa ciljem da model na osnovu poznatih ulaznih obeležja pravilno predvidi kojoj kategoriji novi podatak pripada.

Važno je znati ne samo **koliko** model greši, već i **kako** greši.

Matrica konfuzije

Matrica konfuzije prikazuje odnos između stvarnih klasa i klasa koje je model predvideo.

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

TP, TN, FP i FN

U binarnoj klasifikaciji postoje četiri moguća ishoda:

- ▶ **TP** – stvarno pozitivno, model kaže pozitivno,
- ▶ **TN** – stvarno negativno, model kaže negativno,
- ▶ **FP** – stvarno negativno, model kaže pozitivno,
- ▶ **FN** – stvarno pozitivno, model kaže negativno.

Da li je veći problem False Positive ili False Negative?

Pre izbora metrike pitati: **koju grešku je važnije izbeći u konkretnom problemu?**

Accuracy

Accuracy meri udeo tačnih predikcija u ukupnom broju primera.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- ▶ koristi se kada su klase približno balansirane
- ▶ pogodna metrika kada su različiti tipovi grešaka približno važni

Nedostatak: ne pokazuje koje tipove grešaka model pravi.

Precision

Precision meri koliko su pouzdane pozitivne predikcije modela.

$$Precision = \frac{TP}{TP + FP}$$

Od svih primera koje je model označio kao pozitivne, koliko njih je stvarno pozitivno?

- ▶ pogodna metrika kada su lažno pozitivne predikcije skupe
- ▶ nije dovoljna ako je prioritet prepoznati što veći broj stvarno pozitivnih primera

Recall

Recall meri koliko stvarno pozitivnih primera je model pronašao.

$$Recall = \frac{TP}{TP + FN}$$

Od svih stvarno pozitivnih primera, koliko ih je model uspešno prepoznao?

- pogodna metrika kada je opasno propustiti pozitivan slučaj

F1-score

F1-score je harmonijska sredina precision i recall metrika i koristi se za istovremeno sagledavanje obe vrste grešaka.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

- ▶ koristi se za postizanje ravnoteže između preciznosti i odziva
- ▶ pogodna metrika kada su klase neuravnotežene, a važne su obe vrste grešaka

Prag odlučivanja

Šta se menja kada se promeni prag odlučivanja?


- ▶ veći prag → manje pozitivnih predikcija
- ▶ manji prag → više pozitivnih predikcija

⇒ utiče na **precision** i **recall**

Promena praga odlučivanja menja ponašanje modela bez ponovnog treniranja.

ROC-AUC

ROC kriva prikazuje ponašanje modela kroz različite pragove odlučivanja.



ROC-AUC predstavlja površinu ispod ROC krive.

Klasifikacione metrike u Pythonu

```
from sklearn.metrics import (  
    confusion_matrix,  
    accuracy_score,  
    precision_score,  
    recall_score,  
    f1_score,  
    roc_auc_score  
)  
  
print(confusion_matrix(y_test, y_pred))  
print(accuracy_score(y_test, y_pred))  
print(precision_score(y_test, y_pred))  
print(recall_score(y_test, y_pred))  
print(f1_score(y_test, y_pred))  
print(roc_auc_score(y_test, y_prob))
```

Evaluacija regresije

Regresija

Regresija je tehnika koja se koristi za modelovanje i opisivanje veze između ulaznih podataka i očekivanog izlaza kada je cilj predviđanje kontinualnih vrednosti.

Evaluacija se zasniva na **razlici između stvarne vrednosti i predikcije**.

MAE i R^2 score

MAE meri prosečnu apsolutnu grešku modela.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- ▶ izražen je u istoj jedinici kao ciljna promenljiva
- ▶ lako se tumači u kontekstu konkretnog problema

R^2 score opisuje koliko model objašnjava varijabilnost ciljne promenljive.

- ▶ 1 obično znači bolji model
- ▶ 0 znači da model nije mnogo bolji od jednostavne prosečne predikcije

MAE pokazuje veličinu greške, dok R^2 daje opštu procenu.

MSE i RMSE

MSE meri prosečnu kvadratnu grešku, a **RMSE** njen kvadratni koren.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$RMSE = \sqrt{MSE}$$

- ▶ MSE posebno naglašava velika odstupanja
- ▶ RMSE je izražen u istoj jedinici kao ciljna promenljiva

Kvadratne greške su korisne kada velike greške treba posebno kazniti.

Regresione metrike u Pythonu

```
from sklearn.metrics import (  
    mean_absolute_error,  
    mean_squared_error,  
    root_mean_squared_error,  
    r2_score  
)  
  
print(mean_absolute_error(y_test, y_pred))  
print(mean_squared_error(y_test, y_pred))  
print(root_mean_squared_error(y_test, y_pred))  
print(r2_score(y_test, y_pred))
```

Izbor evaluacione metrike

Izbor metrike zavisi od prirode problema i posledica grešaka koje model pravi.

Pri izboru metrike važno je razmotriti:

- ▶ tip problema: klasifikacija ili regresija
- ▶ raspodelu klasa
- ▶ cenu različitih tipova grešaka
- ▶ značaj velikih odstupanja
- ▶ način tumačenja rezultata u realnom kontekstu

Ne postoji univerzalno najbolja metrika.

Metrika treba da odgovara onome što je za konkretan problem zaista važno.

Problem podele podataka

Rezultat modela može zavisiti od toga kako smo slučajno podelili podatke.

⇒ jedna podela može dati previše optimističan ili pesimističan rezultat.

Jedan train/test split nije uvek dovoljan za pouzdanu procenu.

Koja tehnika se koristi za stabilniju procenu performansi?

Unakrsna validacija

Cross-validation daje stabilniju procenu performansi modela.

Posebno korisno:

- ▶ kada dataset nije veliki
- ▶ pri poređenju različitih modela
- ▶ pri izboru hiperparametara

Tok razvoja modela:

1. treniranje i validacija
2. izbor modela i podešavanje parametara
3. finalna provera na test skupu

K-fold unakrsna validacija

K-fold cross-validation je tehnika evaluacije u kojoj se skup podataka deli na K približno jednakih delova.

U svakoj od K iteracija:

- ▶ jedan deo se koristi za validaciju
- ▶ preostalih $K - 1$ delova koristi se za obuku modela

Konačna procena dobija se agregacijom rezultata iz svih iteracija.

Zaključak

Evaluacija modela nije samo računanje jedne metrike.

Cilj je proceniti:

- ▶ **koliko model dobro generalizuje**
- ▶ **koliko je rezultat stabilan**
- ▶ kakve greške pravi
- ▶ da li je metrika usklađena sa problemom

Dobar model je onaj koji stabilno radi na novim podacima i pravi prihvatljive greške za konkretan problem.

Od studenta se očekuje da u potpunosti razume proces evaluacije: obrazložiti izbor metrike u skladu sa problemom i objasniti kriterijum po kom dobijeni rezultat zadovoljava postavljeni cilj.