

Softverski algoritmi u sistemima automatskog upravljanja

Metode zasnovane na rastojanju i sličnosti

Emina Demirović

Katedra za automatsko upravljanje
Departman za računarstvo i automatiku
Fakultet tehničkih nauka

Sadržaj termina

- ▶ metode zasnovane na rastojanju i sličnosti - osnovna ideja
- ▶ rastojanje i sličnost
- ▶ KNN - ideja, algoritam i primena
- ▶ izbor broja suseda
- ▶ klasteri i klasterizacija
- ▶ K-Means - ideja i algoritam
- ▶ izbor broja klastera
- ▶ redukcija dimenzionalnosti - koncept
- ▶ PCA - ideja, algoritam i primena
- ▶ detekcija anomalija - koncept
- ▶ KNN, LOF i Isolation Forest

Metode zasnovane na rastojanju i sličnosti

Ideja

Ako su dva podatka slična, njihovi predstavnici u prostoru atributa treba da budu blizu.

Na ovoj ideji zasnivaju se:

- ▶ KNN algoritam
- ▶ K-Means klasterizacija
- ▶ PCA vizualizacija
- ▶ pojedini pristupi detekciji anomalija

Podaci u prostoru atributa

Svaki podatak se posmatrati kao objekat u prostoru atributa.

- ▶ jedan atribut - jedna dimenzija (prava)
- ▶ dva atributa - 2D prostor (ravan)
- ▶ tri i više atributa - hiperravan

Broj atributa određuje dimenzionalnost prostora u kom algoritam posmatra podatke.

Rastojanje i sličnost

Rastojanje i sličnost opisuju istu ideju iz dva ugla:

što je rastojanje manje, podaci se smatraju sličnijim.

Rastojanje ima smisla samo ako su atributi dobro pripremljeni.

Sličnost zavisi od izabranih atributa, načina merenja i skaliranja podataka.

Kako priprema podataka utiče na ponašanje algoritma kod metoda zasnovanih na rastojanju i sličnosti?

Kvalitet rastojanja zavisi od kvaliteta reprezentacije podataka.

Mere rastojanja

Euklidsko rastojanje

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- čest izbor kada atributi imaju uporedivo značenje i skalu

Manhattan rastojanje

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

- čest izbor kada se razlike po atributima posmatraju kao zbir pojedinačnih odstupanja

Uopštenje rastojanja

Minkowski rastojanje

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}}$$

Opštiji oblik rastojanja:

- ▶ $p = 1 \rightarrow$ Manhattan rastojanje
- ▶ $p = 2 \rightarrow$ Euklidsko rastojanje

Izbor mere rastojanja zavisi od prirode podataka i problema koji rešavamo.

Standardizacija i normalizacija

Skaliranje ne menja značenje podataka, već ih dovodi u uporediv oblik.

Standardizacija

Standardizacija podrazumeva transformaciju vrednosti tako da atribut ima srednju vrednost 0 i standardnu devijaciju 1.

- ▶ najčešće: **z-score** transformacija

Normalizacija

Vrednosti se normalizacijom najčešće preslikavaju u unapred zadat opseg.

- ▶ najčešće: **min-max** skaliranje


Kod KNN, K-Means, PCA i sličnih metoda skaliranje je uglavnom **neophodan** korak.

KNN

KNN (K-Nearest Neighbors) je algoritam **nadgledanog učenja**.

Ideja

Novi podatak se klasifikuje na osnovu klasa njegovih K najbližih suseda.



KNN algoritam

Postupak klasifikacije novog podatka:

1. Izabrati broj suseda K
2. Izračunati rastojanje do svih primera iz trening skupa
3. Izabrati K najbližih suseda
4. Pogledati kojoj klasi pripada većina suseda
5. Dodeliti novu instancu toj klasi


Od čega rezultat KNN-a direktno zavisi?

Da li ima smisla koristiti KNN i van klasifikacionih problema?

KNN za regresiju

Regresija

Predikcija se dobija kao prosečna vrednost izlaza najbližih suseda.



Izbor broja suseda

Vrednost K određuje koliko suseda učestvuje u donošenju odluke.

- ▶ malo $K \rightarrow$ odluka zavisi od veoma malog broja primera
- ▶ veliko $K \rightarrow$ odluka se zasniva na širem delu trening skupa

Intuicija

Što je K manje, granica odlučivanja može biti nepravilnija i osetljivija na šum.
Što je K veće, model postaje stabilniji, ali može izgubiti lokalne obrasce.


Šta se može desiti ako model odlučuje na osnovu premalo ili previše suseda?

Vrednost K je **hiperparametar** koji se bira na osnovu validacionih rezultata.

Elbow method za izbor broja suseda

1. trenirati KNN za različite vrednosti K
2. izračunati grešku na validacionom skupu
3. prikazati grešku u odnosu na K
4. izabrati **lakat**

Lakat je vrednost nakon koje se greška više ne smanjuje značajno.



KNN - zaključak

Prednosti

- ▶ jednostavan za razumevanje
- ▶ lako se koristi kao početni model
- ▶ nema složenu fazu obučavanja

Mane

- ▶ spor kod velikih skupova
- ▶ osetljiv na skaliranje i šum
- ▶ slabiji u visokoj dimenzionalnosti

KNN je intuitivan i često jednostavan, ali nije uvek praktičan izbor.

Zašto? Šta je kod KNN-a zapravo skupo?

Šta kad je učenje nenadgledano?

KNN

- ▶ nadgledano učenje
- ▶ labelirani trening podaci
- ▶ cilj: predikcija klase ili vrednosti

Šta kada tačni odgovori nisu unapred poznati?
Kako doći do korisnog rezultata?

Klasterizacija

Ideja

Podaci koji su međusobno slični treba da pripadaju istoj grupi - istom **klasteru**.

Unapred zadate klase nisu dostupne!

Cilj: algoritamski otkriti grupacije u strukturi podataka.

Dobra podela na klastere podrazumeva:

- ▶ podaci unutar istog klastera međusobno bliski
- ▶ podaci iz različitih klastera međusobno udaljeniji

K-Means

K-Means je algoritam **nenadgledanog učenja**.

Ideja

Podeliti podatke u K klastera tako da svaka tačka bude blizu centroidu svog klastera.

Centroid - tačka koja predstavlja centar klastera

- računa se kao srednja vrednost tačaka koje pripadaju tom klasteru

Na koji način se ova ideja može algoritamski realizovati?

K-Means algoritam

Postupak:

1. izabrati broj klastera K
2. inicijalizovati K centroida
3. svaku tačku dodeliti najbližem centroidu
4. ponovo izračunati centroide na osnovu dodeljenih tačaka
5. ponavljati dodelu i ažuriranje dok se centroidi ne stabilizuju

K-Means se može razumeti kroz **iterativno pomeranje centroida**.

Problem: Različita inicijalizacija centroida može dovesti do različitih rezultata.

Kako se može smanjiti uticaj loše inicijalizacije centroida?

Kompaktnost klastera - WCSS

- mera uspešnosti klasterovanja - procena kompaktnosti dobijenih klastera

Ideja

Za svaku tačku izračunati rastojanje do centroida klastera kome pripada.

WCSS (*Within-Cluster Sum of Squares*) predstavlja zbir kvadrata rastojanja svih tačaka do centroida svojih klastera.

Cilj: minimizovati WCSS (inertia) vrednost.

Elbow method za izbor broja klastera

1. pokrenuti K-Means za različite vrednosti K
2. za svaku vrednost izračunati WCSS
3. nacrtati grafik WCSS u odnosu na K
4. izabrati tačku nakon koje smanjenje WCSS nije značajno

Lakat u K-Means kontekstu

Lakat označava kompromis između malog WCSS i jednostavnije podele podataka.

WCSS se prirodno smanjuje kada povećavamo broj klastera, ali to ne znači da je veći broj klastera uvek bolji.

Kako se objašnjava ovaj odnos?

K-Means - zaključak

K-Means je pogodan izbor kada su klasteri kompaktni, jasno razdvojeni i približno pravilnog oblika.

Potencijalni problemi:

- ▶ klasteri nepravilnih oblika
- ▶ klasteri različitih veličina ili gustina
- ▶ izraženi outlieri
- ▶ atributi nisu skalirani

Nisu svi problemi istog tipa – neki su ograničenja samog pristupa!

Koje probleme je smisleno rešavati u okviru K-Means algoritma?

Redukcija dimenzionalnosti

Veliki broj dimenzija može otežati:

- ▶ vizualizaciju podataka
- ▶ tumačenje odnosa između podataka
- ▶ rad metoda zasnovanih na rastojanju

Cilj

Prikazati podatke sa manje atributa, uz što manji gubitak informacije.

Tehnike redukcije dimenzionalnosti:

PCA, t-SNE, UMAP, Autoencoder, Feature selection

PCA

PCA (*Principal Component Analysis*) je tehnika za redukciju dimenzionalnosti koja originalne atribute predstavlja pomoću novih osa.

Ideja

Prva glavna komponenta opisuje pravac najveće varijanse u podacima. Sledeće komponente hvataju preostalu varijansu.

Cilj: Pronaći novu reprezentaciju podataka u kojoj je što više korisnih informacija sačuvano u što manjem broju dimenzija.

PCA algoritam

Tipičan tok:

1. skalirati trening podatke X_{train}
2. naučiti glavne komponente na X_{train}
3. transformisati X_{train} u novi prostor
4. istu transformaciju primeniti na X_{test}

PCA zamenjuje originalne attribute novim komponentama:

$$X_1, X_2, \dots, X_n \rightarrow PC_1, PC_2, \dots, PC_k.$$

Objašnjena varijansa pokazuje koliki deo ukupne varijanse podataka je sačuvan u izabranim glavnim komponentama.

Važno: proceniti da li izabrane komponente zadržavaju dovoljno informacija nakon redukcije dimenzionalnosti!

PCA u praksi

Primeri primene:

- ▶ prikaz višedimenzionalnih podataka u 2D ili 3D prostoru
- ▶ uočavanje grupa, obrazaca i outliera
- ▶ smanjenje broja redundantnih atributa
- ▶ priprema podataka za druge algoritme

PCA može pojednostaviti prostor atributa, ali ne bez posledica:

- ▶ interpretacija može biti teža
- ▶ deo informacije se može izgubiti

Šta ako se neki podatak ne uklapa u uobičajenu ili očekivanu strukturu?

Detekcija anomalija

Anomalija je podatak koji značajno odstupa od očekivanog obrasca.

Primeri:

- ▶ neuobičajena transakcija
- ▶ kvar u senzorskim podacima
- ▶ neobičan zahtev u mrežnom saobraćaju

U prostoru atributa anomalije se posmatraju kao tačke koje se ne uklapaju u okolinu:

- ▶ tačka daleko od većine podataka
- ▶ tačka u oblasti male gustine
- ▶ tačka ne pripada nijednoj uobičajenoj grupi

Da li je svaka udaljena tačka nužno anomalija?

Da li je svaka anomalija nužno greška?

KNN pristup

Ideja

Ako je tačka daleko od svojih najbližih suseda, može se smatrati potencijalnom anomalijom i mora se dalje analizirati.

Anomaly score je numerička ocena koliko podatak odskače od svog okruženja:

- ▶ rastojanje do najbližeg suseda
- ▶ prosečno rastojanje do K najbližih suseda
- ▶ rastojanje do K -tog najbližeg suseda

Što je anomaly score veći, podatak je sumnjiviji; konačna odluka zavisi od odabranog kriterijuma.

LOF

LOF (*Local Outlier Factor*) posmatra anomalije kroz **lokalnu gustinu podataka**.


Ideja

Tačka je sumnjiva ako se nalazi u znatno ređoj oblasti nego njeni najbliži susedi.

LOF ne pita samo koliko je tačka udaljena, već i koliko je neobična u odnosu na svoje lokalno okruženje.

Zašto je lokalni kontekst važan?

Local Outlier Factor (LOF)



Isolation Forest

Isolation Forest je algoritam za detekciju anomalija zasnovan na pretpostavci da se neuobičajeni podaci lakše izdvajaju iz skupa.

Ideja

Ako se tačka može izolovati u malom broju podela, verovatno jeste anomalija.

Postupak:

1. podaci se više puta dele po nasumično izabranim atributima i vrednostima podele
2. za svaku tačku se prati koliko podela je potrebno do izolacije
3. tačke koje se izoluju brzo imaju veći anomaly score

Kod anomalija nije dovoljno samo pronaći tačke koje odskoču; važno je razumeti **zašto**.